


一元线性回归模型 的参数估计

高中统计学·第捌课

何濯羽·2024年2月23日



1. 一元线性回归模型

+

2. 最小二乘法

+

3. 矩量估计法

4. 最小二乘估计量的无偏性

5. 线性模型的拟合效果



第一节

一元线性回归模型

□ □ □ □ □ □ □ □ □ □



什么是线性回归模型？

根据“分解性质”，任一随机变量 Y 可以被分解为

$$Y = E(Y|X) + e$$

条件期望函数 误差项

我们的目标是找到条件期望函数 $m(X) = E(Y|X)$ 的解析式。

基于理论知识，或者出于运算简便的考虑，我们假设 $m(X)$ 是一个线性函数： $m(X) = \alpha + \beta X$ 。

线性回归模型：


$$Y = \alpha + \beta X + e$$

因变量 自变量 误差项

常数项 自变量的系数



什么是一元线性回归模型？



当线性回归模型只有一个自变量时，我们称其为 “**一元线性回归模型**” (simple linear regression model) 。

$$Y = \alpha + \beta X_1 + e$$

当线性回归模型有两个或两个以上自变量时，我们称其为 “**多元线性回归模型**” (general linear regression model) 。


$$Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + e$$

在高中阶段，我们仅学习一元线性回归模型的相关知识。

第二节

最小二乘法





如何估计一元线性回归模型的参数？

一元线性回归模型一共有 2 个参数亟待估计： α 和 β 。

在本节与下一节，我们将学习两种常见的构建估计量的方法——它们的结果相同，但路径不同。

考虑到数学教材的“权威性”（😞），我们先学习“**最小二乘法**”（method of least square）。

最小二乘法的思路：


我们的目标是寻找 α 和 β 的取值（记作 $\hat{\alpha}$ 和 $\hat{\beta}$ ），使得下方的二元函数取得最小值：

$$S(\alpha, \beta) = E[(Y - \alpha - \beta X)^2] = E(e^2)$$

由于我们无法直接观测总体（即各随机变量的联合概率分布和矩），我们可以选择先用样本数据估计 $S(\alpha, \beta)$ ，记作 $\hat{S}(\alpha, \beta)$ ，然后寻找 α 和 β 的合适取值使得 $\hat{S}(\alpha, \beta)$ 取得最小值。

根据样本类似原则，我们可以构建如下的估计量：

$$\hat{S}(\alpha, \beta) = \frac{1}{n} \sum_{i=1}^n (Y_i - \alpha - \beta X_i)^2$$





最小二乘法

如何最小化 $\hat{S}(\alpha, \beta) = \frac{1}{n} \sum_{i=1}^n (Y_i - \alpha - \beta X_i)^2$?

首先, $\frac{1}{n}$ 与 α, β 的取值无关, 所以我们的目标转变为: 寻找 α, β 使得 $\hat{Q}(\alpha, \beta) = \sum_{i=1}^n (Y_i - \alpha - \beta X_i)^2$ 最小化。

接着, 开始枯燥的数学推导:

$$\hat{Q}(\alpha, \beta) = \sum_{i=1}^n [Y_i - \beta X_i - (\bar{Y} - \beta \bar{X}) + (\bar{Y} - \beta \bar{X}) - \alpha]^2$$


$$= \sum_{i=1}^n [(Y_i - \bar{Y}) - \beta(X_i - \bar{X}) + (\bar{Y} - \beta \bar{X}) - \alpha]^2$$

$$= \underbrace{\sum_{i=1}^n [(Y_i - \bar{Y}) - \beta(X_i - \bar{X})]^2}_{\textcircled{1}} + \underbrace{2 \sum_{i=1}^n [(Y_i - \bar{Y}) - \beta(X_i - \bar{X})] \cdot [(\bar{Y} - \beta \bar{X}) - \alpha]}_{\textcircled{2}} + \underbrace{\sum_{i=1}^n [(\bar{Y} - \beta \bar{X}) - \alpha]^2}_{\textcircled{3}}$$

①

②


③






最小二乘法

第②项



$$\begin{aligned} & \sum_{i=1}^n [(Y_i - \bar{Y}) - \beta(X_i - \bar{X})] \cdot [(\bar{Y} - \beta\bar{X}) - \alpha] \\ &= (\bar{Y} - \beta\bar{X} - \alpha) \sum_{i=1}^n [(Y_i - \bar{Y}) - \beta(X_i - \bar{X})] \\ &= (\bar{Y} - \beta\bar{X} - \alpha) \left[\sum_{i=1}^n (Y_i - \bar{Y}) - \beta \sum_{i=1}^n (X_i - \bar{X}) \right] \\ &= (\bar{Y} - \beta\bar{X} - \alpha) [(n\bar{Y} - n\bar{Y}) - \beta(n\bar{X} - n\bar{X})] \\ &= 0 \end{aligned}$$



最小二乘法

这样, $\hat{Q}(\alpha, \beta)$ 只剩下第①项和第③项: $\hat{Q}(\alpha, \beta) = \sum_{i=1}^n [(Y_i - \bar{Y}) - \beta(X_i - \bar{X})]^2 + \sum_{i=1}^n [(\bar{Y} - \beta\bar{X}) - \alpha]^2$

其中, 第③项仅与 α 有关, 与 β 无关。因此, 要使得 $\hat{Q}(\alpha, \beta)$ 最小, 我们必须选择使得第③项为 0 的 α 值。这样, α 的取值为

$$\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}$$

将 $\hat{\alpha}$ 和 $\hat{\beta}$ 代入 $\hat{Q}(\alpha, \beta)$ 后, 我们得到

$$\hat{Q}(\hat{\alpha}, \hat{\beta}) = \sum_{i=1}^n [(Y_i - \bar{Y}) - \hat{\beta}(X_i - \bar{X})]^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 - 2\hat{\beta} \sum_{i=1}^n (Y_i - \bar{Y})(X_i - \bar{X}) + \hat{\beta}^2 \sum_{i=1}^n (X_i - \bar{X})^2$$

仔细观察后, 我们发现: $\hat{Q}(\hat{\alpha}, \hat{\beta})$ 是一个关于 $\hat{\beta}$ 的开口向上的一元二次函数。因此, $\hat{Q}(\hat{\alpha}, \hat{\beta})$ 的最小值在其对称轴上取得:

$$\hat{\beta} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

第三节


矩量估计法





与各矩量对应的样本估计量

矩量 (总体)	估计量 (样本)
$E(X) = \mu_X = \sum_{x \in \mathcal{X}} x \cdot \Pr(X = x)$	$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
$D(X) = \sigma_X^2 = \sum_{x \in \mathcal{X}} (x - \mu_X)^2 \cdot \Pr(X = x)$	$\hat{\sigma}_X^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$
$Cov(X, Y) = \sigma_{XY} = E\{[X - E(X)] \cdot [Y - E(Y)]\}$	$\hat{\sigma}_{XY} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$





矩量估计法

第二种构建一元线性回归模型中参数估计量的方法是“**矩量法**”（method of moments）。

简而言之，矩量法就是先将参数们用模型中相关的随机变量的矩表示出来（即“识别”），然后根据参数的表达式，直接构造估计量。

在第柒课中，我们已经对一元线性回归模型的参数进行了识别：

$$\alpha = E(Y) - \beta \cdot E(X) \quad \beta = \frac{Cov(X, Y)}{D(X)}$$

于是，根据样本类似原则，我们可以构建如下的估计量：


$$\hat{\alpha} = \bar{Y} - \hat{\beta} \bar{X} \quad \hat{\beta} = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

这些估计量与通过最小二乘法构造的估计量一模一样！

第四节

最小二乘估计的无偏性

□ □ □ □ □ □ □ □ □



高斯-马尔可夫定理（简化版）

在一元线性回归模型 $Y = \alpha + \beta X + e$ 中，如果以下假设均成立，那么模型参数的最小二乘估计量就是它们的最优无偏估计量。“最优”指的是该估计量是所有无偏估计量中（条件）方差最小的。

1

独立同分布

样本 $(X_i, Y_i)_{i=1}^n$ 中每一对随机变量 (X, Y) 均相互独立，且服从同一个概率分布。

2

方差非零

自变量 X 的方差不等于 0，即 $D(X) > 0$ 。

3

外生性

误差项的条件期望等于 0，即 $E(e|X) = 0$ 。

4

同质性

误差项的条件方差为一个定值，即 $D(e|X) = \sigma^2 > 0$ 。

该定理经历了三个世纪的完善：由德国数学家高斯（Carl F. Gauss）于1823年提出，由俄国数学家马尔可夫（Andrey A. Markov）于1912年进行无偏性的规范化，再由美国计量经济学家汉森（Bruce E. Hansen）于2022年推广至非线性无偏估计量的领域。

第五节

线性模型的拟合效果





拟合值 & 残差

在我们将样本数据代入一元线性回归模型参数的最小二乘估计量后，我们会得到它们的估计值： $\hat{\alpha}$ 和 $\hat{\beta}$ 。于是，我们可以计算


$$\hat{Y} = \hat{\alpha} + \hat{\beta}X$$

\hat{Y} 被称为“**拟合值**” (fitted value) —— “拟合” 指的是已知某函数的若干离散函数值（来自样本数据），通过调整该函数中若干系数（如 α 和 β ），使得该函数与已知样本点的差距最小。这实际上就是最小二乘法的计算原理。

我们把 Y 的观测值 (observed value) 与拟合值的差称为“**残差**” (residual)：

$$\hat{e} = Y - \hat{Y}$$

样本中，每一个个体都有自己独特的观测值 Y_i 和拟合值 \hat{Y}_i ，所以每一个个体也有自己独特的残差 \hat{e}_i 。



平方和 (Sum of Squares)

✦ 残差平方和

$$SS_{\text{res}} = \sum_{i=1}^n \hat{e}_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

✦ 模型平方和

$$SS_{\text{reg}} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

✦ 总平方和

$$SS_{\text{tot}} = \sum_{i=1}^n (Y_i - \bar{Y})^2$$


当回归模型为（一元或多元）线性模型，且包含常数项时，以下等式恒成立：

$$SS_{\text{tot}} = SS_{\text{res}} + SS_{\text{reg}} \quad \text{即} \quad \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

注：该等式的证明过程较为复杂，在此不做展示。



平方和的图示





决定系数

决定系数 (coefficient of determination) , 又称 “**R方**” (R squared) , 是衡量模型拟合效果的工具。

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$


当回归模型为 (一元或多元) 线性模型, 且包含常数项时, 我们有

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} = \frac{SS_{\text{tot}} - SS_{\text{res}}}{SS_{\text{tot}}} = \frac{SS_{\text{reg}}}{SS_{\text{res}} + SS_{\text{reg}}}$$

因为 $SS_{\text{reg}} \geq 0$, $SS_{\text{res}} \geq 0$, 所以 $R^2 \in [0, 1]$ 。

$R^2 = 1$ (即 $SS_{\text{res}} = 0$) 表明模型的拟合值完美契合了样本的观测值。

注意: 具有完美拟合效果的模型 \neq 好模型!





R方的值域

一般情况下，我们有 $SS_{\text{tot}} \neq SS_{\text{res}} + SS_{\text{reg}}$ 。因此， R^2 的值域不会局限在区间 $[0, 1]$ 内。

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

因为 $SS_{\text{res}} \geq 0$ ， $SS_{\text{tot}} \geq 0$ ，所以 $R^2 \leq 1$ 。

当一个模型过分糟糕时（例如：真实的 CEF 是非线性的而我们却使用了线性模型），我们会发现

$$SS_{\text{res}} > SS_{\text{tot}}$$

于是， $R < 0$ 。




综上，在一般情况下， $R^2 \in (-\infty, 1]$ 。



关于 R^2 方的警告

ALERT



1. R^2 不能用于检测我们所使用模型的正确性。

2. R^2 不能说明我们是否已包含正确的自变量。

3. R^2 不能说明我们是否已收集足够多的样本。

4. R^2 不能解释自变量 X 与因变量 Y 的因果关系。



因为 R^2 在实际应用方面存在极大的误导性，而且近年来 R^2 在学术界的受重视程度愈来愈低，所以我个人完全不能理解人教版 2019A 新教材为何引入 R^2 的相关知识。



感谢各位的倾听

Thanks for your listening!

何濯羽 2024年2月23日